

[Get unlimited access](#)[Open in app](#)

Published in Ciencia y Datos

You have 1 free member-only story left this month. [Upgrade for unlimited access.](#)



Victor Roman

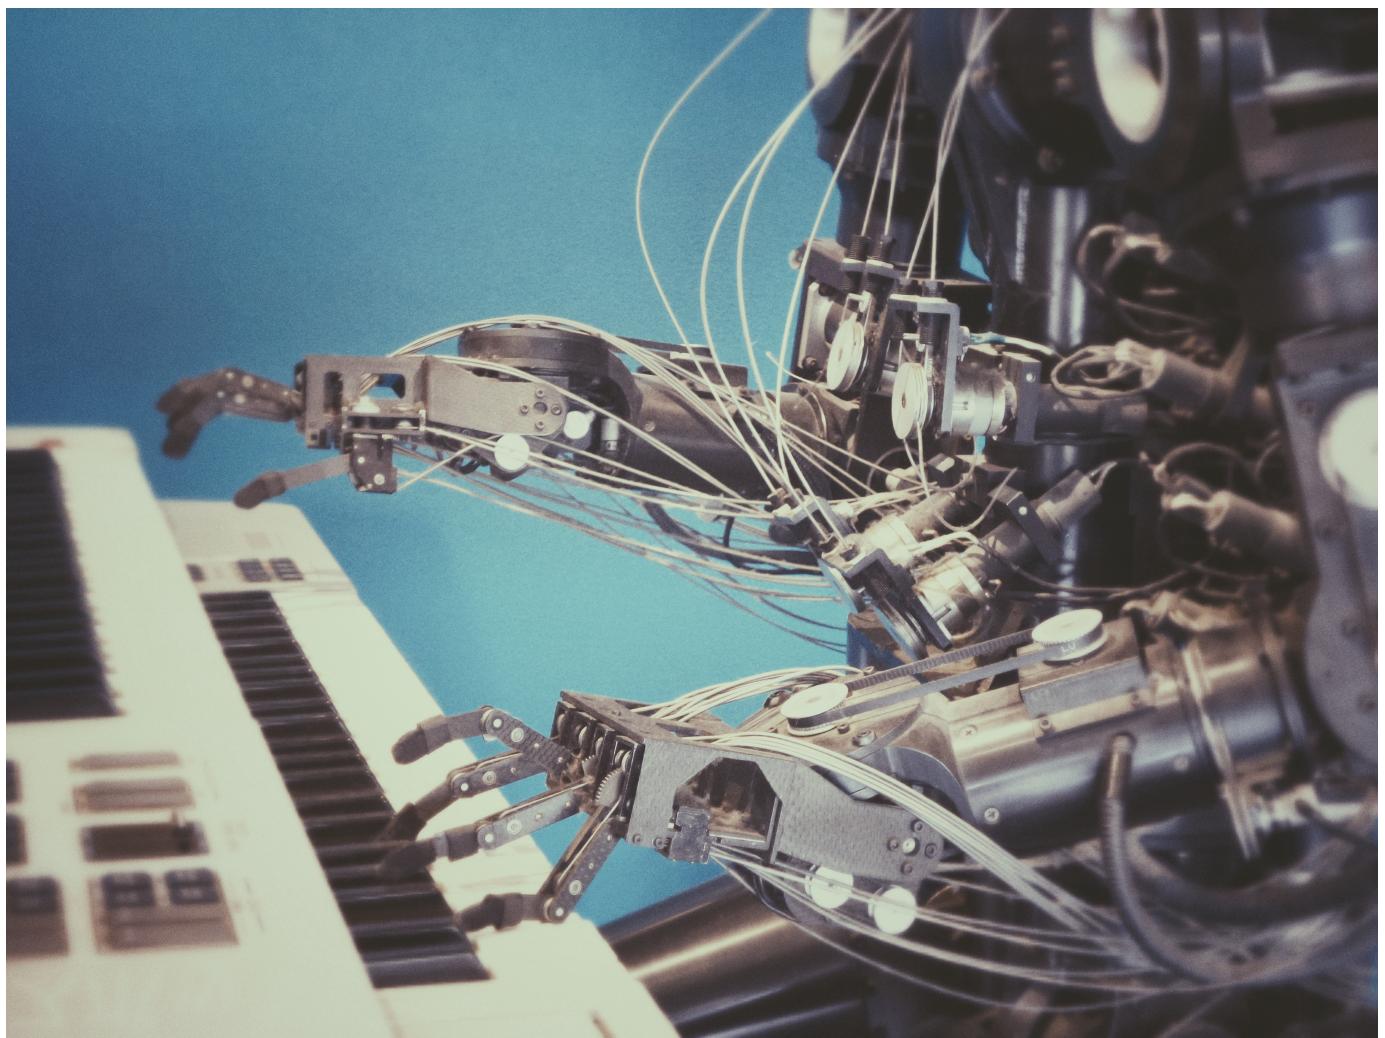
[Follow](#)

Feb 6, 2019 · 10 min read · ✨

...

[Save](#)

## Introducción al Machine Learning: Una Guía Desde Cero



Este es el primero de una serie de artículos en los que expondré los conceptos de Machine Learning (ó Aprendizaje Automático en castellano), los diferentes subcampos que existen, algoritmos e implementaciones en Python.

Los objetivos principales de esta serie de artículos son:

1. Crear una guía sobre los aspectos teóricos e intuitivos de Machine Learning.
2. Mostrar proyectos de Machine Learning, desarrollados en Python, para visualizar de una manera práctica los conceptos y algoritmos involucrados, así como la forma en que pueden ser aplicados en problemas de la vida real.
3. Crear un registro del conocimiento que he adquirido sobre la materia y, si es posible, inspirar a otras personas en el aprendizaje y aplicación de los conceptos y tecnologías de Machine Learning en sus propios campos.



[Get unlimited access](#)[Open in app](#)

- Python Machine Learning book (Sebastian Raschka & Vahid Mirjalili)
- Deep Learning with Python book (Francois Chollet)
- Machine Learning Mastery with Python book (Jason Brownlee)
- Python Data Science and Machine Learning course (Jose Portilla, Udemy)
- Machine Learning y Data Science con Python course (Manuel Garrido, Udemy)

## ¿Qué Es Machine Learning?

Debido al aumento de la capacidad y al abaratamiento de las tecnologías de la información y de los sensores, podemos producir, almacenar y enviar más datos que nunca antes en la historia. De hecho, se calcula que el 90% de los datos disponibles actualmente en el planeta se ha creado en los últimos dos años, produciéndose actualmente en torno a 2,5 quintillones (2.500.000.000.000.000.000) de bytes por día, siguiendo una tendencia fuertemente creciente. Estos datos alimentan los modelos de Machine Learning y son el impulso principal del auge que esta ciencia ha experimentado en los últimos años.

Machine Learning es uno de los subcampos de la Inteligencia Artificial y puede ser definido como:

*“Machine Learning es la ciencia que permite que las computadoras aprendan y actúen como lo hacen los humanos, mejorando su aprendizaje a lo largo del tiempo de una forma autónoma, alimentándolas con datos e información en forma de observaciones e interacciones con el mundo real.” — Dan Fagella*

Machine learning ofrece una manera eficiente de capturar el conocimiento mediante la información contenida en los datos, para mejorar de forma gradual el rendimiento de modelos predictivos y tomar decisiones basadas en dichos datos. Se ha convertido en una tecnología con una amplia presencia, y actualmente está presente en: filtros anti-spam para correo electrónico, conducción automática de vehículos o reconocimiento de voz e imágenes.

A modo de ejemplo, el siguiente vídeo muestra una detección de eventos en tiempo real para una aplicación de video-vigilancia basada en Machine Learning.

Real-time event detection for video surveillance applications



You can now subscribe to get stories delivered directly to your inbox.

Got it

## Terminología Básica y Notaciones

En Machine Learning generalmente se utilizan matrices y notaciones vectoriales para referirnos a los datos, de la siguiente forma:





Get unlimited access

Open in app

- En el caso más general habrá una columna, que llamaremos objetivo, etiqueta o respuesta, y que será el valor que se pretende predecir. (“label” en la imagen inferior).

Features					Label
Position	Experience	Skill	Country	City	Salary (\$)
Developer	0	1	USA	New York	103100
Developer	1	1	USA	New York	104900
Developer	2	218	1	New York	106800
Developer	3	1	USA	New York	108700
Developer	4	1	USA	New York	110400
Developer	5	1	USA	New York	112300
Developer	6	1	USA	New York	114200
Developer	7	1	USA	New York	116100
Developer	8	1	USA	New York	117800
Developer	9	1	USA	New York	119700
Developer	10	1	USA	New York	121600

Existen algoritmos específicos cuyo propósito es “entrenar” los modelos de Machine Learning. Dichos algoritmos proporcionan datos de entrenamiento que permiten a los modelos aprender de ellos.

Con respecto a los algoritmos de Machine Learning, normalmente tienen determinados parámetros “internos”. Por ejemplo en los árboles de decisión, hay parámetros como profundidad máxima del arbol, número de nodos, número de hojas,...a estos parámetros se les llama “hiperparámetros”.

Llamamos “generalización” a la capacidad del modelo para hacer predicciones utilizando nuevos datos.

## Tipos de Machine Learning

Los tipos de Machine Learning que se tratarán en esta serie son:

- Aprendizaje supervisado
- Aprendizaje no supervisado
- Aprendizaje profundo

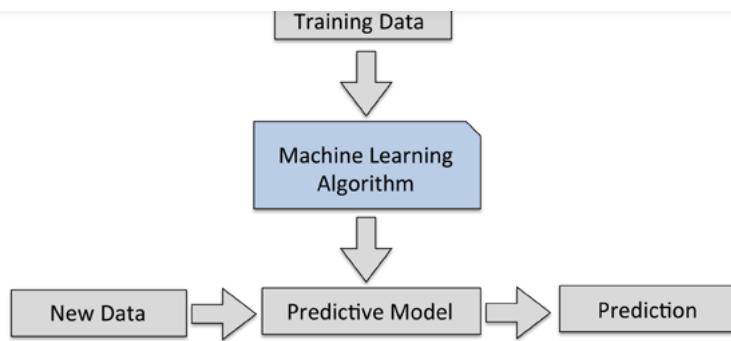
Exploraremos y estudiaremos estos tres tipos, profundizando más especialmente en una clase de técnicas de aprendizaje profundo llamada “aprendizaje reforzado”.

## Aprendizaje Supervisado

Se refiere a un tipo de modelos de Machine Learning que se entrena con un conjunto de ejemplos en los que los resultados de salida son conocidos. Los modelos aprenden de esos resultados conocidos y realizan ajustes en sus parámetros interiores para adaptarse a los datos de entrada. Una vez el modelo es entrenado adecuadamente, y los parámetros internos son coherentes con los datos de entrada y los resultados de la batería de datos de entrenamiento, el modelo podrá realizar predicciones adecuadas ante nuevos datos no procesados previamente.

De forma gráfica:



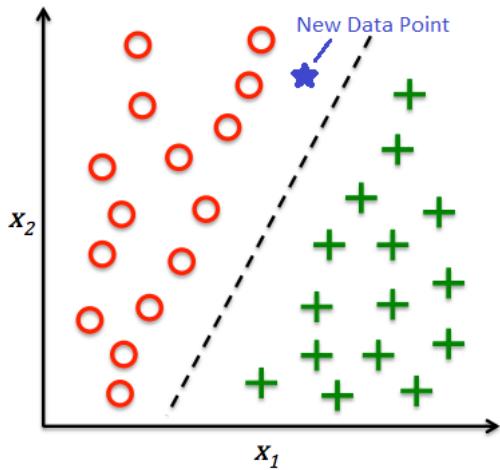


Hay dos aplicaciones principales de aprendizaje supervisado: clasificación y regresión:

### 1. Clasificación:

Clasificación es una sub-categoría de aprendizaje supervisado en la que el objetivo es predecir las clases categóricas (valores discretos, no ordenados, pertenencia a grupos). El ejemplo típico es la detección de correo spam, que es una clasificación binaria (un email es spam — valor “1”- o no lo es — valor “0” -). También hay clasificación multi-clase, como el reconocimiento de caracteres escritos a mano (donde las clases van de 0 a 9).

Un ejemplo de clasificación binaria: hay dos clases de objetos, círculos y cruces, y dos características de los objetos,  $X_1$  y  $X_2$ . El modelo puede encontrar las relaciones entre las características de cada punto de datos y su clase, y establecer la linea divisoria entre ellos. Así, al ser alimentado con nuevos datos, el modelo será capaz de determinar la clase a la que pertenecen, de acuerdo con sus características.

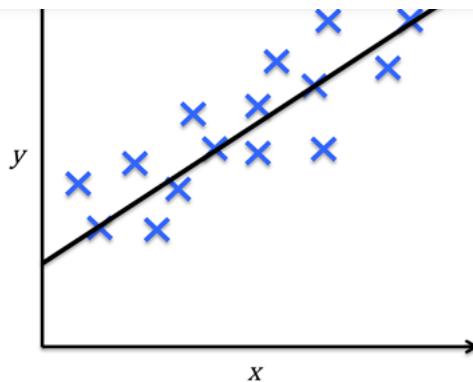


En este caso, el nuevo punto de datos entra en el área correspondiente al subespacio de círculos y por tanto, el modelo predecirá que la clase del objeto es círculo.

### 2. Regresión:

La regresión se utiliza para asignar categorías a datos sin etiquetar. En este tipo de aprendizaje tenemos un número de variables predictoras (explicativas) y una variable de respuesta continua (resultado), y se tratará de encontrar una relación entre dichas variables que nos proporciona un resultado continuo.

Un ejemplo de regresión lineal: dados X e Y, establecemos una linea recta que minimice la distancia (con el método de mínimos cuadrados) entre los puntos de muestra y la línea ajustada. Después, utilizaremos las desviaciones obtenidas en la formación de la línea para predecir nuevos datos de salida.



## Aprendizaje No Supervisado

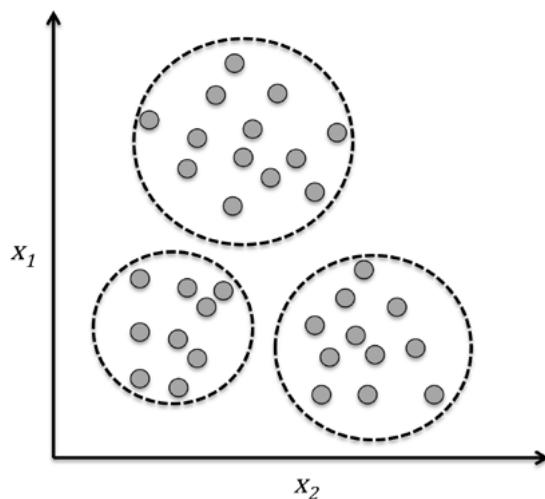
En el aprendizaje no supervisado, trataremos con datos sin etiquetar cuya estructura es desconocida. El objetivo será la extracción de información significativa, sin la referencia de variables de salida conocidas, y mediante la exploración de la estructura de dichos datos sin etiquetar.

Hay dos categorías principales: agrupamiento y reducción dimensional.

### 1. Agrupamiento ó Clustering:

El agrupamiento es una técnica exploratoria de análisis de datos, que se usa para organizar información en grupos con significado sin tener conocimiento previo de su estructura. Cada grupo es un conjunto de objetos similares que se diferencia de los objetos de otros grupos. El objetivo es obtener un numero de grupos de características similares.

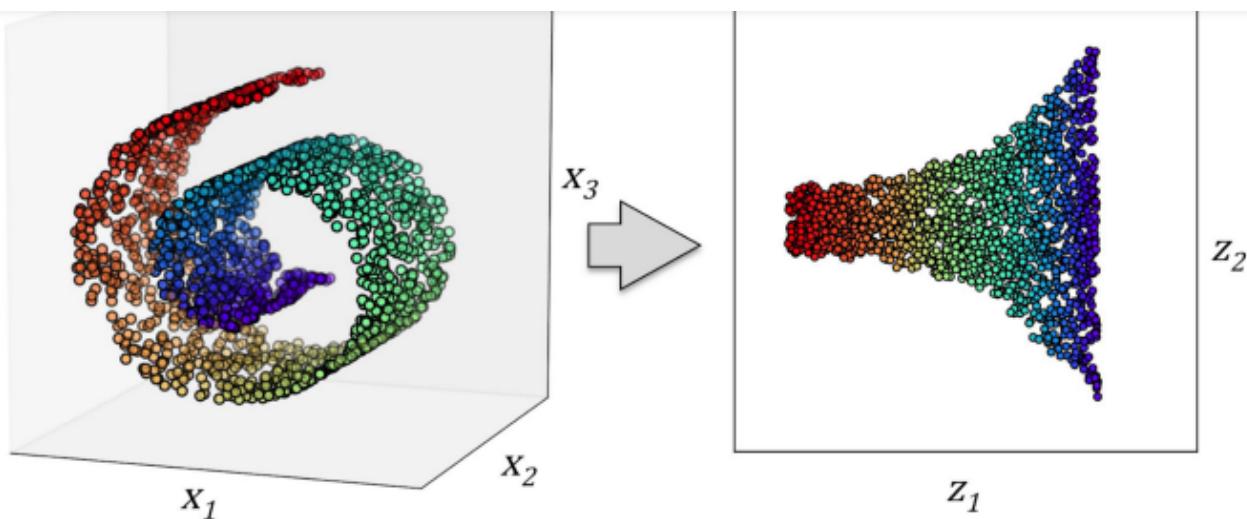
Un ejemplo de aplicación de este tipo de algoritmos puede ser para establecer tipos de consumidores en función de sus hábitos de compra, para poder realizar técnicas de marketing efectivas y “personalizadas”.



### 2. Reducción dimensional:

Es común trabajar con datos en los que cada observación se presenta con alto número de características, en otras palabras, que tienen alta dimensionalidad. Este hecho es un reto para la capacidad de procesamiento y el rendimiento computacional de los algoritmos de Machine Learning. La reducción dimensional es una de las técnicas usadas para mitigar este efecto.

La reducción dimensional funciona encontrando correlaciones entre las características, lo que implica que existe información redundante, ya que alguna característica puede explicarse parcialmente con otras (por ejemplo, puede existir dependencia lineal). Estas técnicas eliminan “ruido” de los datos (que puede también empeorar el comportamiento del modelo), y comprimen los datos en un sub-espacio más reducido, al tiempo que retienen la mayoría de la información relevante.



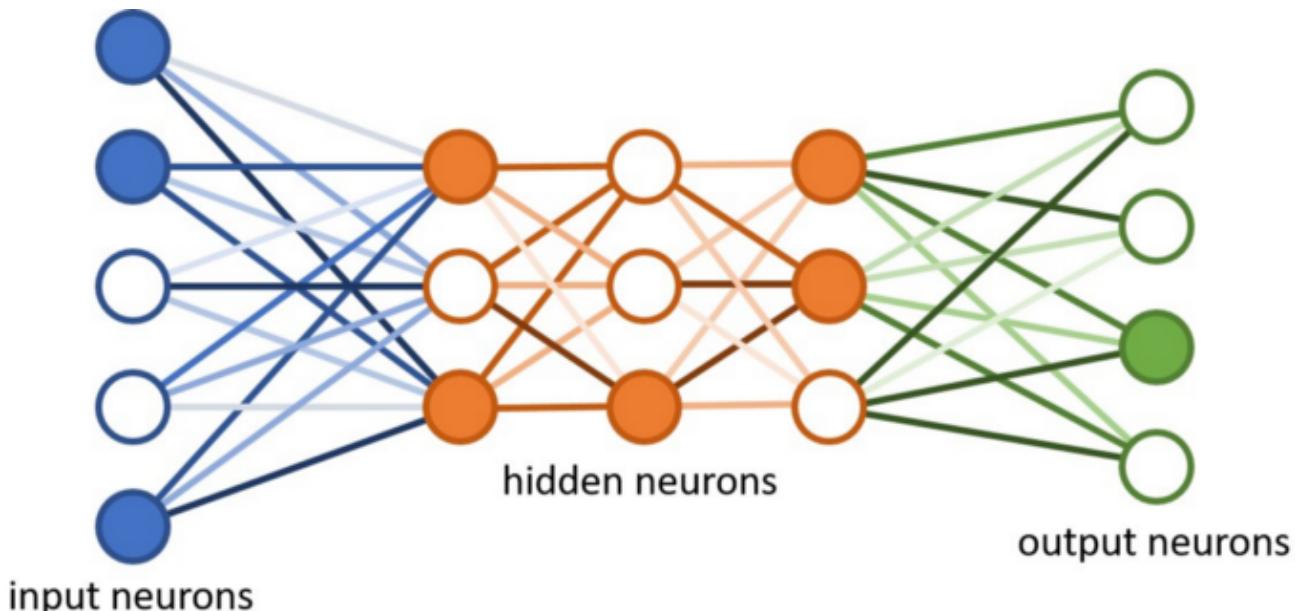
## Deep Learning

El aprendizaje profundo ó Deep Learning, es un subcampo de Machine Learning, que usa una estructura jerárquica de redes neuronales artificiales, que se construyen de una forma similar a la estructura neuronal del cerebro humano, con los nodos de neuronas conectadas como una tela de araña. Esta arquitectura permite abordar el análisis de datos de forma no lineal.

La primera capa de la red neuronal toma datos en bruto como entrada, los procesa, extrae información y la transfiere a la siguiente capa como salida. Este proceso se repite en las siguientes capas, cada capa procesa la información proporcionada por la capa anterior, y así sucesivamente hasta que los datos llegan a la capa final, que es donde se obtiene la predicción.

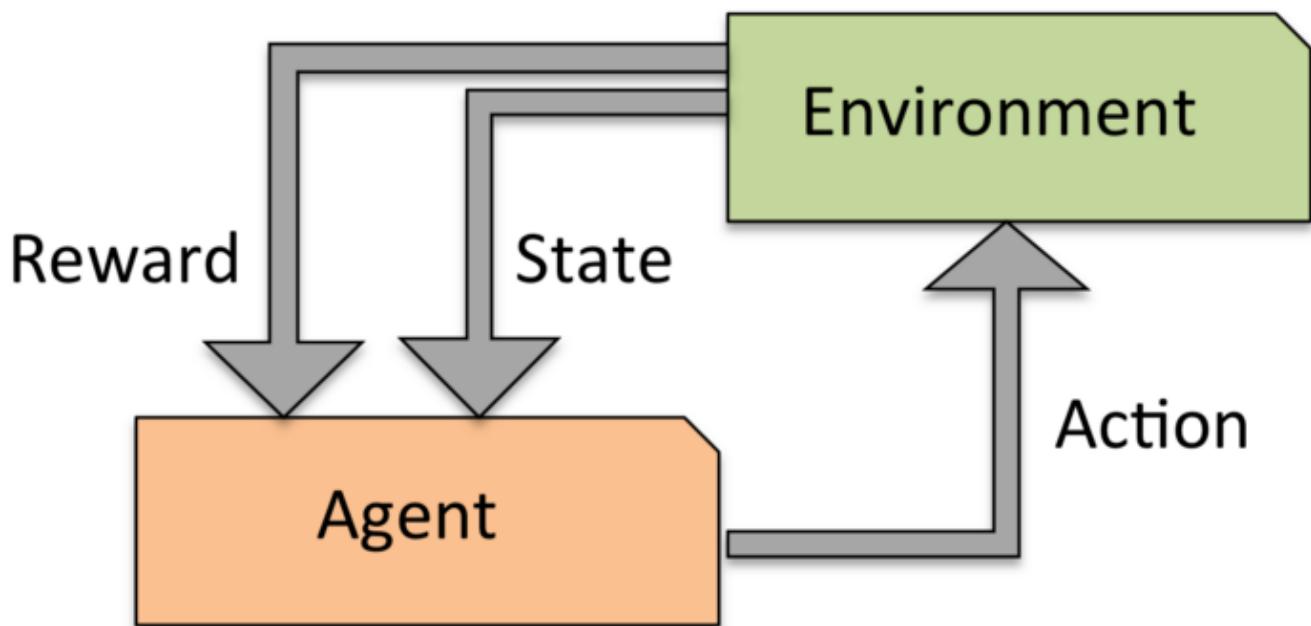
Esta predicción se compara con el resultado conocido, y así por análisis inverso el modelo es capaz de aprender los factores que conducen a salidas adecuadas.

Es uno de los principales algoritmos utilizados en la creación de aplicaciones y programas para reconocimiento de imágenes.

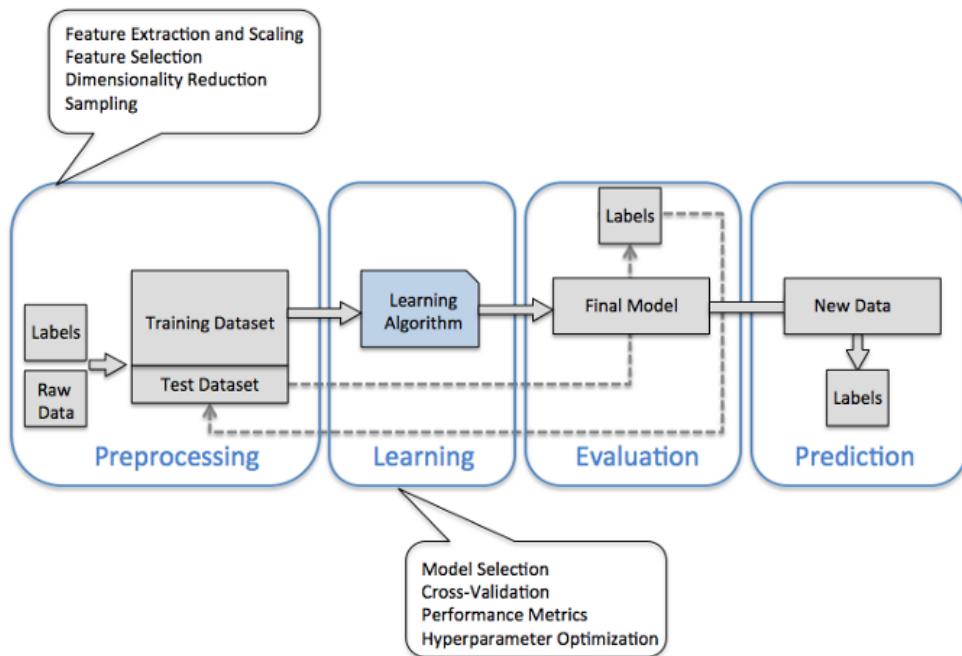


## Aprendizaje reforzado

El aprendizaje reforzado es una de las ramas más importantes del aprendizaje profundo. El objetivo es construir un modelo con un agente que mejora su rendimiento, basándose en la recompensa obtenida del entorno con cada interacción que se realiza. La recompensa es una medida de lo correcta que ha sido una acción para obtener un objetivo determinado. El agente utiliza esta



### Metodología general para construir modelos de Machine Learning



#### Preprocesamiento:

Este es uno de los pasos más importantes en cualquier aplicación de Machine Learning. Usualmente los datos se presentan en formatos no óptimos (o incluso inadecuados) para ser procesados por el modelo. En estos casos el pre-procesamiento de datos es una tarea que se debe realizar de manera obligatoria.

Muchos algoritmos requieren que las características estén en la misma escala (por ejemplo, en el rango [0,1]) para optimizar su rendimiento, lo que se realiza frecuentemente aplicando técnicas de normalización o estandarización en los datos.

Podemos también encontrar en algunos casos que las características seleccionadas están correlacionadas, y por tanto son redundantes

[Get unlimited access](#)[Open in app](#)

## Entrenando y seleccionando un modelo

Es esencial comparar los diferentes algoritmos de un grupo para entrenar y seleccionar el de mejor rendimiento. Para realizar esto, es necesario seleccionar una métrica para medir el rendimiento del modelo.

Una de ellas comúnmente usada en problemas de clasificación es la precisión de clasificación, que es la proporción de instancias correctamente clasificadas.

En los problemas de regresión, uno de los más comunes es el Error Cuadrático Medio (MSE), que mide la diferencia media cuadrática entre los valores estimados y los reales.

$$MSE = \frac{1}{N} \sum_{i=1}^N (f_i - y_i)^2$$

where  $N$  is the number of data points,  
 $f_i$  the value returned by the model and  
 $y_i$  the actual value for data point  $i$ .

Para asegurarnos de que nuestro modelo funcionará adecuadamente con datos reales, utilizaremos la técnica denominada validación cruzada antes de utilizar el conjunto de datos de prueba para la evaluación final del modelo.

Esta técnica divide el conjunto de datos de entrenamiento en subconjuntos menores de entrenamiento y validación, con lo que se estima la capacidad de generalización del modelo. En otras palabras, estimando cómo de correctas serán las predicciones de salida obtenidas cuando el modelo se alimenta con datos nuevos. A continuación, se repite el proceso K veces y se calcula el rendimiento medio del modelo dividiendo la suma de las métricas obtenidas entre el número K de interacciones.



En general, los parámetros por defecto de los algoritmos de Machine Learning proporcionados por las librerías no son los mejores para utilizar con nuestros datos, por lo que usaremos técnicas de optimización de “hiperparámetros” para ayudarnos a realizar el ajuste fino del rendimiento del modelo.

## Evaluando Modelos y Prediciendo con Datos Nuevos

Una vez que hemos seleccionado y ajustado un modelo a nuestro conjunto de datos de entrenamiento, podemos usar los datos de prueba para estimar el rendimiento del modelo en los datos nuevos, por lo que podemos hacer una estimación del error de generalización del modelo, o evaluarlo utilizando alguna otra métrica.

Si estamos satisfechos con el valor de la métrica obtenida, podremos usar el modelo para realizar predicciones con los datos futuros.

## Resumen

En este artículo hemos mostrado unas pinceladas de lo que significa Machine Learning, un cuadro general de su naturaleza, propósito y aplicaciones.



[Get unlimited access](#)[Open in app](#)

- Aprendizaje supervisado, con técnicas de clasificación y regresión.
- Aprendizaje no supervisado, con agrupamiento y reducción dimensional.
- Aprendizaje reforzado, en el que el agente aprende del entorno.
- Aprendizaje profundo y sus redes neuronales artificiales.

Finalmente, introdujimos la metodología típica para construir modelos de Machine Learning y explicamos sus tareas principales:

- Preprocesamiento.
- Entrenamiento y pruebas.
- Selección del modelo.
- Evaluación.

Según se comentó al principio del artículo, éste es el primero de una serie y pretende servir como introducción general. El objetivo es que la serie sea recorrido estimulante según se vaya mostrando cómo aplicar variadas y potentes técnicas.

Por la naturaleza técnica de la serie, se mostrarán aspectos de cálculo, álgebra lineal, estadística y conceptos de Python, ya que será necesario para entender los conceptos principales y cómo funcionan los algoritmos. Pero no os preocupéis si no tenéis formación específica al respecto, ya que realizaremos una aproximación ligera a todos estos conceptos.

En las siguientes entregas, explicaremos cómo establecer un entorno de programación Python con las librerías adecuadas. También estaremos listos para comenzar un estudio más profundo de aprendizaje supervisado.

¡Seguid conectados!

